Sieci Kohonena

Martyna Sadowska, nr indeksu 333157

Wstęp

W tym projekcie wprowadzona została implementacja sieci Kohonena z prostokątną i sześciokątną topologią neuronów służącej do klasteryzacji i wizualizacji wielowymiarowych danych. Testowany był wpływ rozmiaru siatki, szerokości sąsiedztwa oraz dwóch funkcji sąsiedztwa: gaussowskiej i meksykańskiego kapelusza. Skuteczność zaimplementowanych algorytmów przetestowano początkowo na syntetycznych, prostych zbiorach danych przestrzennych, a następnie na bardziej złożonych, rzeczywistych zbiorach.

Podstawowa sieć Kohonena

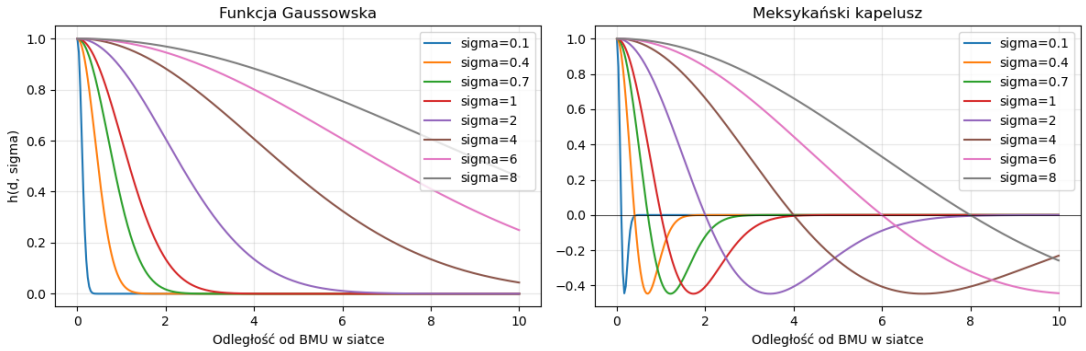
Na pierwszym etapie zaimplementowana została sieć Kohonena złożona z neuronów w prostokątnej siatce M×N, która działa dla zbioru wektorów o tej samej długości. Zaimplementowane zostały dwie funkcje sąsiedztwa - funkcja gaussowska oraz meksykański kapelusz. Funkcja Gaussa przyciąga neurony z siłą proporcjonalną do odległości od neuronu zwycięskiego, natomiast meksykański kapelusz odpycha pewnych dalszych sąsiadów, co pozwala na wyostrzenie granic między klastrami. Obie funkcje pozwalają na zmianę szerokości sąsiedztwa z użyciem parametru sigma. Jako funkcję wygaszającą uczenie wraz z kolejnymi iteracjami użyta została funkcja $\alpha(t) = e^{-\frac{t}{\lambda}}$. Wagi sieci są inicjalizowane z rozkładu jednostajnego na przedziale od minimalnej do maksymalnej wartości występującej w zbiorze danych.

Na tym etapie testy były prowadzone na dwóch zbiorach danych: hexagon (dane 2D skupione w wierzchołkach sześciokąta) oraz cube (dane 3D skupione w wierzchołkach sześcianu). Etykiety danych, uprzednio poddane kodowaniu one-hot, służyły wyłącznie do wizualizacji i oceny poprawności wyników.

Aby przetestować wpływ hiperparametrów modelu na wyniki, zastosowano metodę przeszukiwania siatki parametrów. Testowane były jedynie siatki kwadratowe, więc zamiast oznaczeń N i M używane jest jedynie N na rozmiar siatki. Siatka użyta w przeszukiwaniu dla obu zbiorów jest widoczna w tabeli 1. We wszystkich przypadkach model był trenowany przez 100 epok z parametrem wygaszania $\lambda = 50$. Na wykresie 1 zaprezentowano wartości funkcji sąsiedztwa względem dystansu od zwycięskiego neuronu (BMU), wygenerowane dla testowanych parametrów sigma.

Parametr	Wartości
N	4, 6, 10
sigma	0.1, 0.4, 0.7, 1, 2, 4, 6, 8
funkcje	funkcja Gaussa, meksykański kapelusz

Tabela 1: Siatka parametrów użyta w przeszukiwaniu.



Rysunek 1: Wartości funkcji sąsiedztwa względem dystansu od zwycięskiego neuronu (BMU), wygenerowane dla testowanych parametrów sigma.

Poprawność klasteryzacji była oceniana wizualnie oraz dzięki wartości Accuracy rozumianej jako miara czystości klastrów. Wyznaczano ją poprzez przypisanie każdemu neuronowi najczęściej występującej w nim etykiety, a następnie

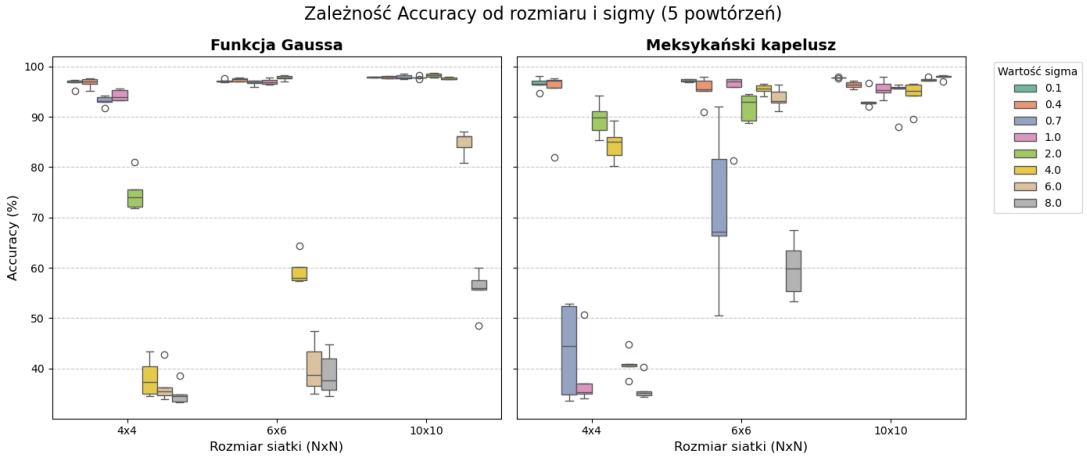
obliczenie, jaka część całego zbioru danych została sklasyfikowana zgodnie z tym przypisaniem. Aby zapewnić powtarzalność wyników, eksperyment został powtórzony 5 razy. Pełne wyniki posortowane po średnim wyniku Accuracy są dostępne w tabeli 2 dla danych hexagon i w tabeli 3 dla danych cube. Są one zwizualizowane na wykresie 2 dla danych hexagon i wykresie 3 dla danych cube.

	Rozmiar	Sigma	Funkcja	Średnia Acc (%)	Odchylenie Std
0	10x10	2.0	funkcja Gaussa	98.266	0.347
1	10x10	0.7	funkcja Gaussa	97.966	0.430
2	10x10	0.4	funkcja Gaussa	97.936	0.253
3	10x10	8.0	meksykanski kapelusz	97.934	0.535
4	10x10	0.1	funkcja Gaussa	97.932	0.093
5	10x10	1.0	funkcja Gaussa	97.864	0.297
6	10x10	0.1	meksykanski kapelusz	97.832	0.117
7	6x6	2.0	funkcja Gaussa	97.800	0.519
8	10x10	4.0	funkcja Gaussa	97.666	0.235
9	10x10	6.0	meksykanski kapelusz	97.434	0.345
10	6x6	0.4	funkcja Gaussa	97.400	0.383
11	6x6	0.1	meksykanski kapelusz	97.200	0.299
12	6x6	0.1	funkcja Gaussa	97.134	0.323
13	6x6	1.0	funkcja Gaussa	96.964	0.616
14	4x4	0.4	funkcja Gaussa	96.768	1.004
15	6x6	0.7	funkcja Gaussa	96.768	0.481
16	4x4	0.1	funkcja Gaussa	96.734	0.893
17	4x4	0.1	meksykanski kapelusz	96.568	1.284
18	10x10	0.4	meksykanski kapelusz	96.366	0.661
19	10x10	1.0	meksykanski kapelusz	95.598	1.760
20	6x6	4.0	meksykanski kapelusz	95.502	0.979
21	6x6	0.4	meksykanski kapelusz	95.368	2.707
22	10x10	2.0	meksykanski kapelusz	94.366	3.567
23	10x10	4.0	meksykanski kapelusz	94.334	2.862
24	4x4	1.0	funkcja Gaussa	94.298	1.123
25	4x4	0.4	meksykanski kapelusz	94.000	6.745
26	6x6	1.0	meksykanski kapelusz	93.866	7.035
27	6x6	6.0	meksykanski kapelusz	93.700	2.003
28	10x10	0.7	meksykanski kapelusz	93.434	1.848
29	4x4	0.7	funkcja Gaussa	93.168	0.964
30	6x6	2.0	meksykanski kapelusz	91.934	2.738
31	4x4	2.0	meksykanski kapelusz	89.566	3.420
32	10x10	6.0	funkcja Gaussa	84.834	2.499
33	4x4	4.0	meksykanski kapelusz	84.534	3.455
34	4x4	2.0	funkcja Gaussa	74.900	3.717
35	6x6	0.7	meksykanski kapelusz	71.534	15.891
36	6x6	8.0	meksykanski kapelusz	59.898	5.805
37	6x6	4.0	funkcja Gaussa	59.466	2.947
38	10x10	8.0	funkcja Gaussa	55.534	4.287
39	4x4	0.7	meksykanski kapelusz	43.632	9.189
40	4x4	6.0	meksykanski kapelusz	40.866	2.608
41	6x6	6.0	funkcja Gaussa	40.200	5.152
42	6x6	8.0	funkcja Gaussa	38.966	4.332
43	4x4	1.0	meksykanski kapelusz	38.400	6.944
44	4x4	4.0	funkcja Gaussa	38.132	3.751
45	4x4	6.0	funkcja Gaussa	36.600	3.592
46	4x4	8.0	meksykanski kapelusz	36.000	2.462
47	4x4	8.0	funkcja Gaussa	34.932	2.094

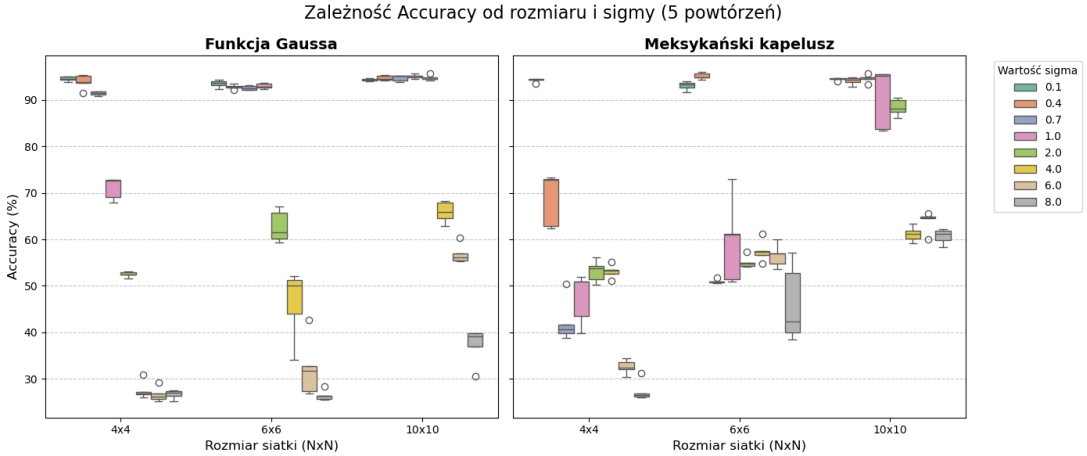
Tabela 2: Średnie wyniki Accuracy wraz z odchyleniem standardowym uzyskane po 5 wywołaniach dla konkretnych kombinacji hiperparametrów modelu dla zbioru hexagon. Wartości posortowane malejąco po średnim Accuracy.

	Rozmiar	Sigma	Funkcja	Średnia Acc (%)	Odchylenie Std
0	6x6	0.4	meksykanski kapelusz	95.098	0.641
1	10x10	1.0	funkcja Gaussa	95.052	0.449
2	10x10	2.0	funkcja Gaussa	94.684	0.542
3	10x10	0.4	funkcja Gaussa	94.664	0.523
4	10x10	0.7	funkcja Gaussa	94.630	0.622
5	10x10	0.7	meksykanski kapelusz	94.616	0.878
6	4x4	0.1	funkcja Gaussa	94.500	0.477
7	10x10	0.1	meksykanski kapelusz	94.418	0.257
8	10x10	0.1	funkcja Gaussa	94.316	0.281
9	4x4	0.1	meksykanski kapelusz	94.200	0.411
10	10x10	0.4	meksykanski kapelusz	94.032	0.823
11	4x4	0.4	funkcja Gaussa	93.866	1.552
12	6x6	0.1	funkcja Gaussa	93.466	0.822
13	6x6	0.1	meksykanski kapelusz	93.036	0.898
14	6x6	1.0	funkcja Gaussa	92.932	0.561
15	6x6	0.4	funkcja Gaussa	92.802	0.458
16	6x6	0.7	funkcja Gaussa	92.534	0.447
17	4x4	0.7	funkcja Gaussa	91.416	0.417
18	10x10	1.0	meksykanski kapelusz	90.616	6.463
19	10x10	2.0	meksykanski kapelusz	88.366	1.804
20	4x4	1.0	funkcja Gaussa	71.030	2.394
21	4x4	0.4	meksykanski kapelusz	68.868	5.663
22	10x10	4.0	funkcja Gaussa	65.868	2.220
23	10x10	6.0	meksykanski kapelusz	63.932	2.235
24	6x6	2.0	funkcja Gaussa	62.782	3.405
25	10x10	4.0	meksykanski kapelusz	61.150	1.589
26	10x10	8.0	meksykanski kapelusz	60.650	1.594
27	6x6	1.0	meksykanski kapelusz	59.534	8.989
28	6x6	4.0	meksykanski kapelusz	57.484	2.310
29	10x10	6.0	funkcja Gaussa	56.852	2.096
30	6x6	6.0	meksykanski kapelusz	56.436	2.403
31	6x6	2.0	meksykanski kapelusz	55.100	1.294
32	4x4	2.0	meksykanski kapelusz	53.184	2.390
33	4x4	4.0	meksykanski kapelusz	53.132	1.425
34	4x4	2.0	funkcja Gaussa	52.536	0.573
35	6x6	0.7	meksykanski kapelusz	51.032	0.437
36	4x4	1.0	meksykanski kapelusz	47.434	5.438
37	6x6	4.0	funkcja Gaussa	46.332	7.507
38	6x6	8.0	meksykanski kapelusz	46.118	8.339
39	4x4	0.7	meksykanski kapelusz	42.252	4.693
40	10x10	8.0	funkcja Gaussa	37.232	3.900
41	4x4	6.0	meksykanski kapelusz	32.618	1.566
42	6x6	6.0	funkcja Gaussa	32.300	6.358
43	4x4	4.0	funkcja Gaussa	27.552	1.926
44	4x4	8.0	meksykanski kapelusz	27.366	2.239
45	4x4	8.0	funkcja Gaussa	26.698	0.925
46	4x4	6.0	funkcja Gaussa	26.636	1.547
47	6x6	8.0	funkcja Gaussa	26.450	1.125

Tabela 3: Średnie wyniki Accuracy wraz z odchyleniem standardowym uzyskane po 5 wywołaniach dla konkretnych kombinacji hiperparametrów modelu dla zbioru cube. Wartości posortowane malejąco po średnim Accuracy.



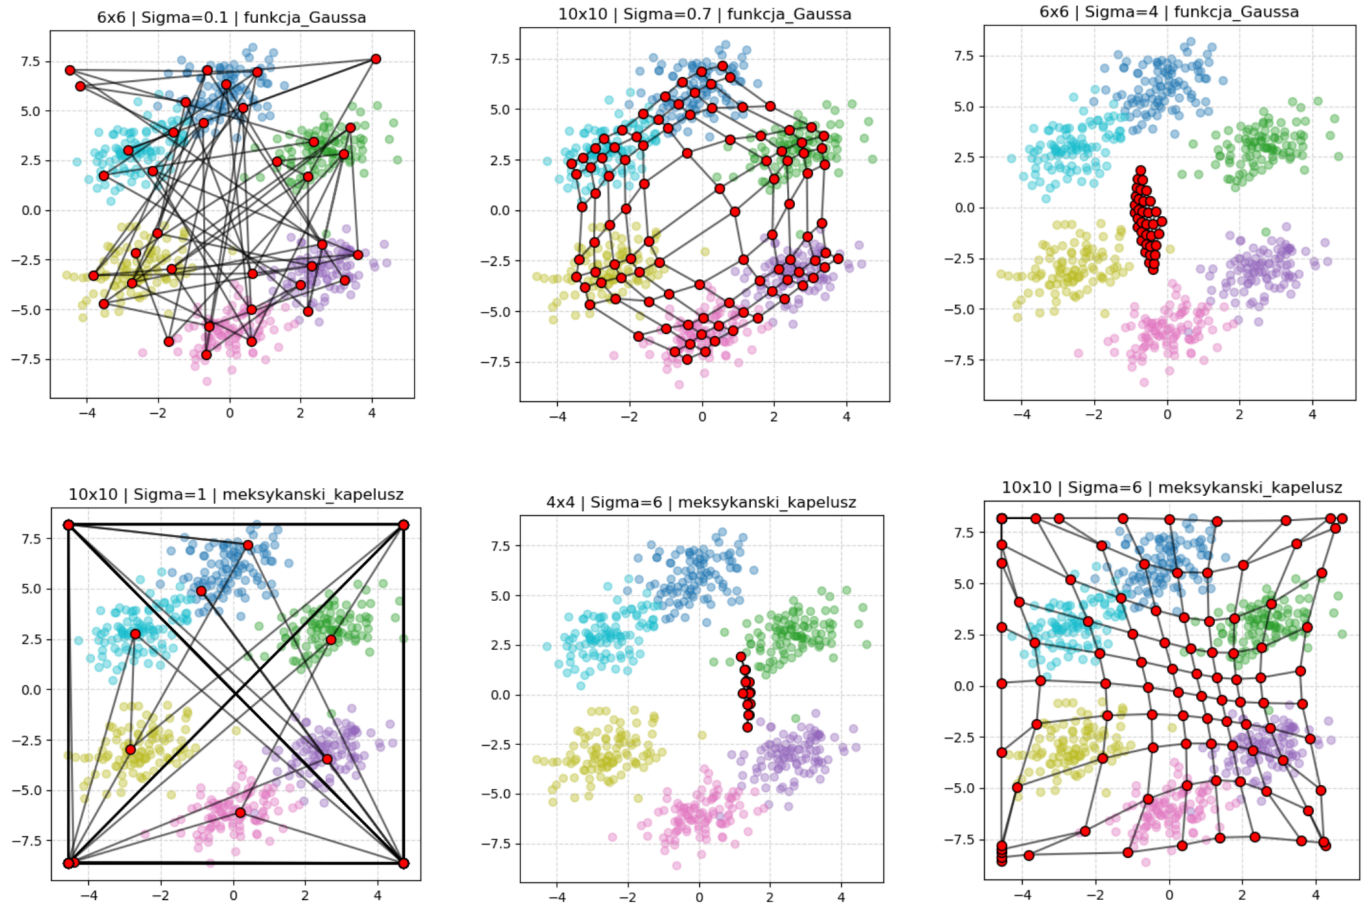
Rysunek 2: Wartości Accuracy w zależności od funkcji, rozmiaru siatki oraz wartości sigma dla zbioru danych hexagon.



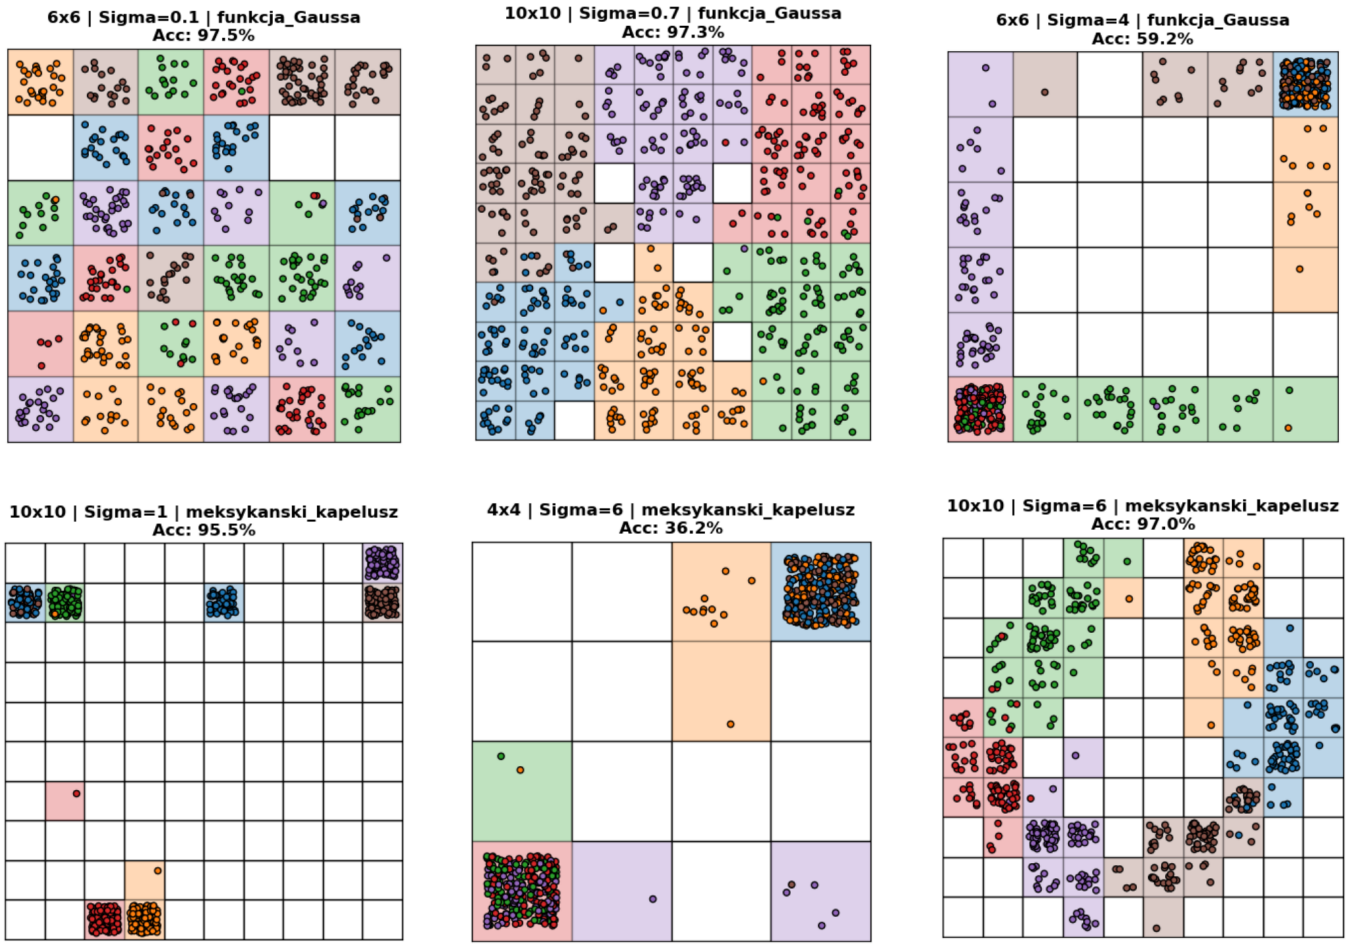
Rysunek 3: Wartości Accuracy w zależności od funkcji, rozmiaru siatki oraz wartości sigma dla zbioru danych cube.

Na wykresach 4 widoczne są przykładowe wykresy dopasowania siatki Kohonena do zbioru hexagon dla jednego z wywołań. Można zauważyć, że sieć z funkcją Gaussa i zbyt małą wartością sigma miała tendencje do krzyżowania połączeń, natomiast zbyt duża wartość sigma powodowała, że sieć zbyt mocno się do siebie przyciągała i zbijała się w jednym miejscu. Podczas treningu modelu, wagi były zawsze przycinane do obszaru danych, aby nie odpychały się do nieskończoności. Zastosowanie tego widać na wykresach modeli z funkcją meksykańskiego kapelusza i małą sigmą. Niektóre neurony zanim złapały daną z klastra zostały na tyle odepchnięte, że do końca zostawały na krawędziach obszaru poszukiwań. Widać również, że meksykański kapelusz potrzebował większej siatki dla wyższych wartości sigma, aby odpowiednio rozprzestrzenić się po danych.

Wykresy 5 przedstawiają mapy trafień uzyskane dla badanych modeli w tym samym przebiegu. Obrazują one, do jakich klastrów zostały przyporządkowane poszczególne próbki. Kolory kropek oznaczają prawdziwe etykiety danych, natomiast kolor tła danego neuronu odpowiada klasie dominującej, czyli tej, która występuje w nim najczęściej. Można było zauważyć, że krzyżowanie połączeń przy funkcji Gaussa skutkowało stworzeniem większej liczby klastrów niż w badanych danych, jednak zostały one bardzo dobrze od siebie oddzielone, niewiele neuronów trafiło do klastra innego koloru. Bardzo dobre wyniki dawała sigma z przedziału $(0.1 - 1]$ - klastry widocznie się od siebie oddzielały, ich liczba odpowiadała liczbie klastrów danych, a w obrębie pojedynczego neuronu znajdowały się w znacznej większości dane z tylko jednej klasy. Im większa sigma, tym spadała wartość Accuracy, co było spowodowane tym, że sieć skupiała się w jednym miejscu i większość danych trafiała do dwóch skrajnych neuronów. Znaczącą różnicą w modelach używających funkcji meksykańskiego kapelusza było wiele nieaktywnych neuronów - dane jednej klasy skupiały się w dużo mniejszej liczbie neuronów niż miało to miejsce w przypadku funkcji Gaussa. Dla sigmy równej 1 widać, że pojedyncze neurony są odpowiedzialne za wszystkie dane z klasy. W małej siatce z większą sigmą mamy do czynienia z analogicznym problemem jak przy funkcji Gaussa - siatka nie rozprzestrzeniła się na całe dane, przez co skrajne neurony zebrały większość danych, co wpłynęło na znacząco niższe Accuracy. Zwiększenie siatki pozwoliło na dużo lepszy podział danych - liczba klastrów prawie odpowiada liczbie klas w danych i większość neuronów ma dane tylko z jednej klasy.

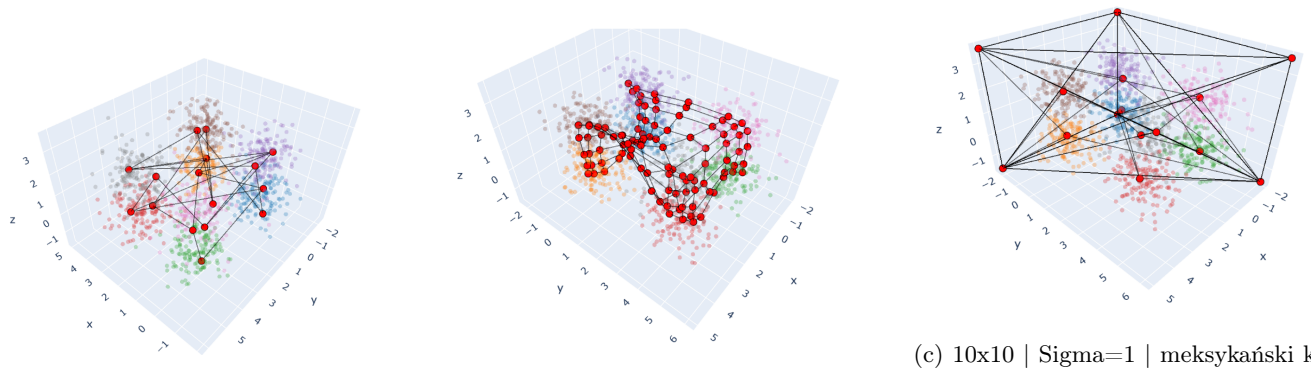


Rysunek 4: Wykresy dopasowania siatki Kohonena do zbioru hexagon dla różnych hiperparametrów opisanych przez rozmiar siatki NxN, wartość sigma i funkcję sąsiedztwa.



Rysunek 5: Mapy trafień siatki Kohonena do zbioru hexagon dla różnych hiperparametrów opisanych przez rozmiar siatki NxN, wartość sigma i funkcję sąsiedztwa wraz z wyliczoną wartością Accuracy.

Na wykresach 6 widoczne są przykładowe wykresy 3D dopasowania siatki Kohonena do zbioru cube dla jednego z wywołań. Natomiast na wykresach 7 widoczne są mapy trafień uzyskane dla badanych modeli w tym samym przebiegu. Można z nich wyciągnąć wnioski analogiczne jak dla zbioru hexagon. Tutaj funkcja meksykańskiego kapelusza dawała gorsze wyniki, a zwiększanie wartości sigma nie poprawiało ich tak, jak w przypadku zbioru hexagon. Podział na tę samą liczbę klastrów, co faktyczny zbiór danych następował rzadziej i częściej zdarzały się neurony z różnych klas w jednym neuronie w porównaniu do zbioru hexagon. Mimo tego, wiele modeli dawało wysoką wartość Accuracy.

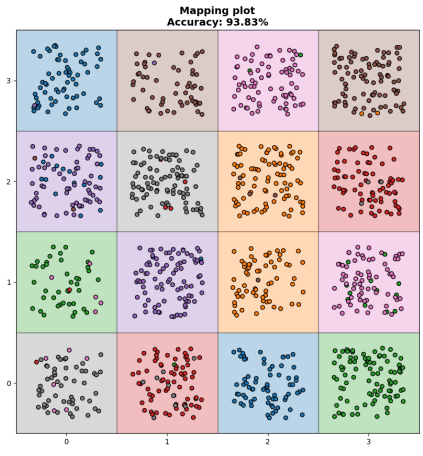


(a) 4x4 | Sigma=0.2 | funkcja Gaussa

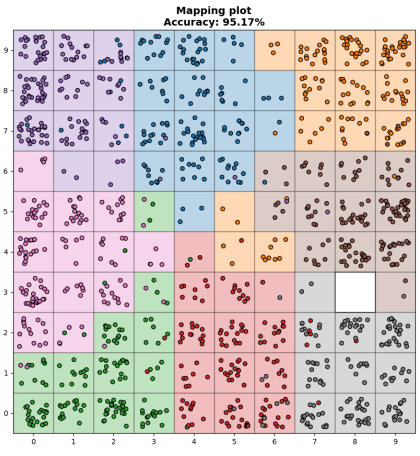
(b) 10x10 | Sigma=1 | funkcja Gaussa

(c) 10x10 | Sigma=1 | meksykański kapelusz

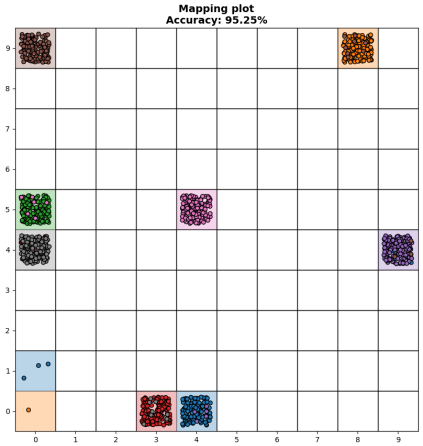
Rysunek 6: Wykresy dopasowania siatki Kohonena do zbioru cube dla różnych hiperparametrów opisanych przez rozmiar siatki NxN, wartość sigma i funkcję sąsiedztwa.



(a) 4x4 | Sigma=0.2 | funkcja Gaussa



(b) 10x10 | Sigma=1 | funkcja Gaussa



(c) 10x10 | Sigma=1 | meksykański kapelusz

Rysunek 7: Mapy trafień siatki Kohonena do zbioru cube dla różnych hiperparametrów opisanych przez rozmiar siatki NxN, wartość sigma i funkcję sąsiedztwa wraz z wyliczoną wartością Accuracy.

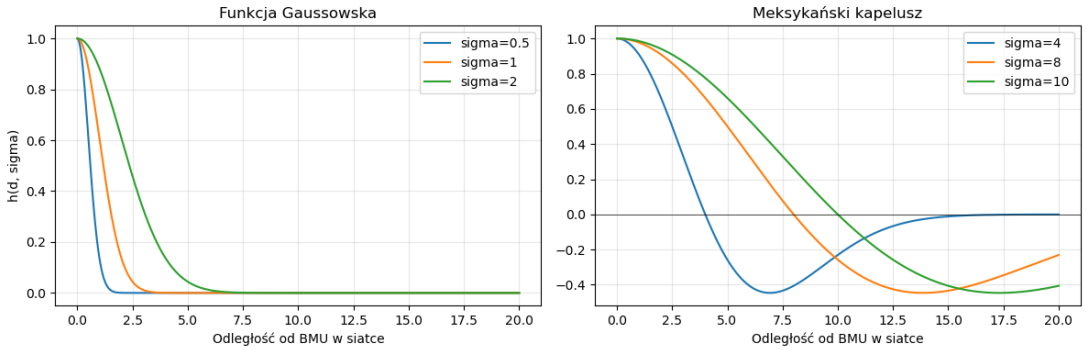
Po analizie wszystkich wykresów i wyników Accuracy, można wyciągnąć kilka wniosków dotyczących architektury modelu zarówno dla zbioru hexagon jak i cube. Funkcja Gaussa dawała zwykle lepsze lub bardziej stabilne wyniki. Dla niej najlepiej sprawdzała się sigma z zakresu $(0.1 - 1]$. Sigma o wartości 0.1 dawała zadowalające wyniki, lecz dzieliła zbiór na więcej klastrów niż rzeczywiste dane. Dla sigmy równej 2 potrzebne było zwiększenie siatki, a dla wyższych wartości sigmy poprawność podziału klas drastycznie spadała. Funkcja meksykańskiego kapelusza dużo wyraźniej oddzielała klastry i do dobrych wyników potrzebowała wyższych wartości sigmy, czyli zakresu neuronów, które przyciągamy zamiast odpychać. Chociaż funkcja meksykańskiego kapelusza dawała wiele nieaktywnych neuronów, to zarówno dla niej jak i dla funkcji Gaussa zwiększenie siatki poprawiało wynik Accuracy.

Sieć Kohonena na siatce sześciokątnej

Na tym etapie została dodana możliwość wyboru siatki sześciokątnej jako podstawy modelu sieci. Testy były prowadzone na dwóch zbiorach danych: MNIST (zbiór obrazów odręcznie pisanych cyfr) oraz HAR (dane z sensorów smartfonów dotyczące aktywności fizycznej). Warto zaznaczyć, że przed testowaniem danych MNIST zastosowano globalną normalizację - wszystkie wartości były dzielone przez 255. Aby przyspieszyć testowanie, użyto jedynie 10 000 elementów zbioru MNIST oraz zmniejszono liczbę epok i współczynnik wygaszania. Korzystając z wniosków z poprzednich testów, zmieniono sposób testowania sigmy w siatce - dla funkcji Gaussa używano mniejszych wartości sigmy, a dla meksykańskiego kapelusza większych. Konkretne testowane parametry umieszczone są w tabeli 4. Na wykresie 8 zaprezentowano wartości funkcji sąsiedztwa względem dystansu od zwycięskiego neuronu (BMU), wygenerowane dla testowanych parametrów sigma.

Parametr	Wartości dla danych MNIST	Wartości dla danych HAR
epoki	4	10
współczynnik wygaszania	2	5
N	8, 12, 16	5, 10, 15
sigma dla funkcji Gaussa	0.5, 1, 2	
sigma dla meksykańskiego kapelusza	4, 8, 10	
funkcje	funkcja Gaussa, meksykański kapelusz	
topologie	sześciokąt, kwadrat	

Tabela 4: Siatka parametrów użyta w przeszukiwaniu.



Rysunek 8: Wartości funkcji sąsiedztwa względem dystansu od zwycięskiego neuronu (BMU), wygenerowane dla testowanych parametrów sigma.

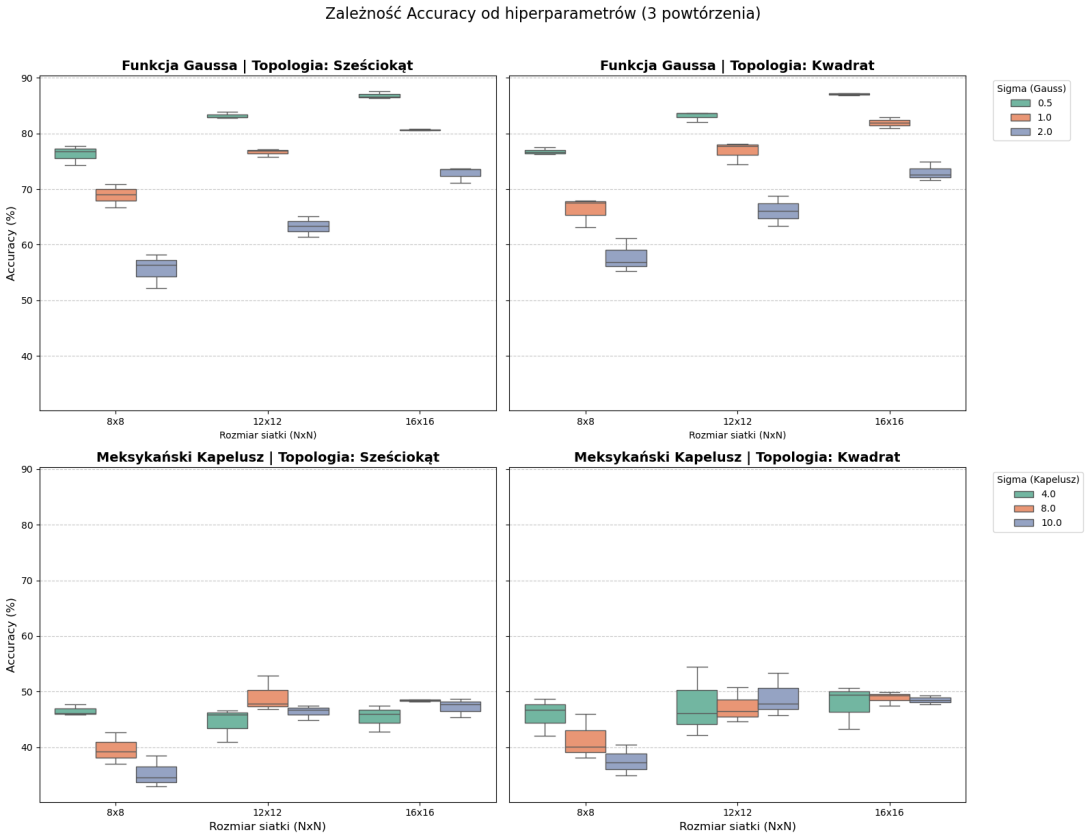
Przeszukiwanie hiperparametrów po siatce wykonano 3 razy, aby zapewnić powtarzalność wyników. Pełne wyniki posortowane po średnim wyniku Accuracy są dostępne w tabeli 5 dla danych MNIST i w tabeli 6 dla danych HAR. Są one zwizualizowane na wykresie 9 dla danych MNIST i wykresie 10 dla danych HAR.

	Rozmiar	Sigma	Funkcja	Topologia	Średnia Acc (%)	Odchylenie Std
0	16x16	0.5	funkcja Gaussa	kwadrat	87.057	0.191
1	16x16	0.5	funkcja Gaussa	szesciokat	86.823	0.701
2	12x12	0.5	funkcja Gaussa	szesciokat	83.210	0.566
3	12x12	0.5	funkcja Gaussa	kwadrat	83.147	0.933
4	16x16	1.0	funkcja Gaussa	kwadrat	81.937	1.000
5	16x16	1.0	funkcja Gaussa	szesciokat	80.623	0.131
6	12x12	1.0	funkcja Gaussa	kwadrat	76.787	2.025
7	8x8	0.5	funkcja Gaussa	kwadrat	76.763	0.657
8	12x12	1.0	funkcja Gaussa	szesciokat	76.587	0.746
9	8x8	0.5	funkcja Gaussa	szesciokat	76.297	1.756
10	16x16	2.0	funkcja Gaussa	kwadrat	73.037	1.670
11	16x16	2.0	funkcja Gaussa	szesciokat	72.770	1.438
12	8x8	1.0	funkcja Gaussa	szesciokat	68.877	2.097
13	8x8	1.0	funkcja Gaussa	kwadrat	66.190	2.691
14	12x12	2.0	funkcja Gaussa	kwadrat	66.077	2.695
15	12x12	2.0	funkcja Gaussa	szesciokat	63.307	1.840
16	8x8	2.0	funkcja Gaussa	kwadrat	57.773	3.050
17	8x8	2.0	funkcja Gaussa	szesciokat	55.563	3.088
18	12x12	8.0	meksykanski kapelusz	szesciokat	49.147	3.224
19	12x12	10.0	meksykanski kapelusz	kwadrat	48.967	3.908
20	16x16	8.0	meksykanski kapelusz	kwadrat	48.890	1.235
21	16x16	10.0	meksykanski kapelusz	kwadrat	48.527	0.780
22	16x16	8.0	meksykanski kapelusz	szesciokat	48.423	0.162
23	16x16	4.0	meksykanski kapelusz	kwadrat	47.800	3.976
24	12x12	4.0	meksykanski kapelusz	kwadrat	47.563	6.294
25	12x12	8.0	meksykanski kapelusz	kwadrat	47.280	3.167
26	16x16	10.0	meksykanski kapelusz	szesciokat	47.250	1.749
27	8x8	4.0	meksykanski kapelusz	szesciokat	46.557	1.035
28	12x12	10.0	meksykanski kapelusz	szesciokat	46.387	1.349
29	8x8	4.0	meksykanski kapelusz	kwadrat	45.853	3.425
30	16x16	4.0	meksykanski kapelusz	szesciokat	45.413	2.339
31	12x12	4.0	meksykanski kapelusz	szesciokat	44.463	3.104
32	8x8	8.0	meksykanski kapelusz	kwadrat	41.377	4.073
33	8x8	8.0	meksykanski kapelusz	szesciokat	39.637	2.838
34	8x8	10.0	meksykanski kapelusz	kwadrat	37.530	2.769
35	8x8	10.0	meksykanski kapelusz	szesciokat	35.347	2.883

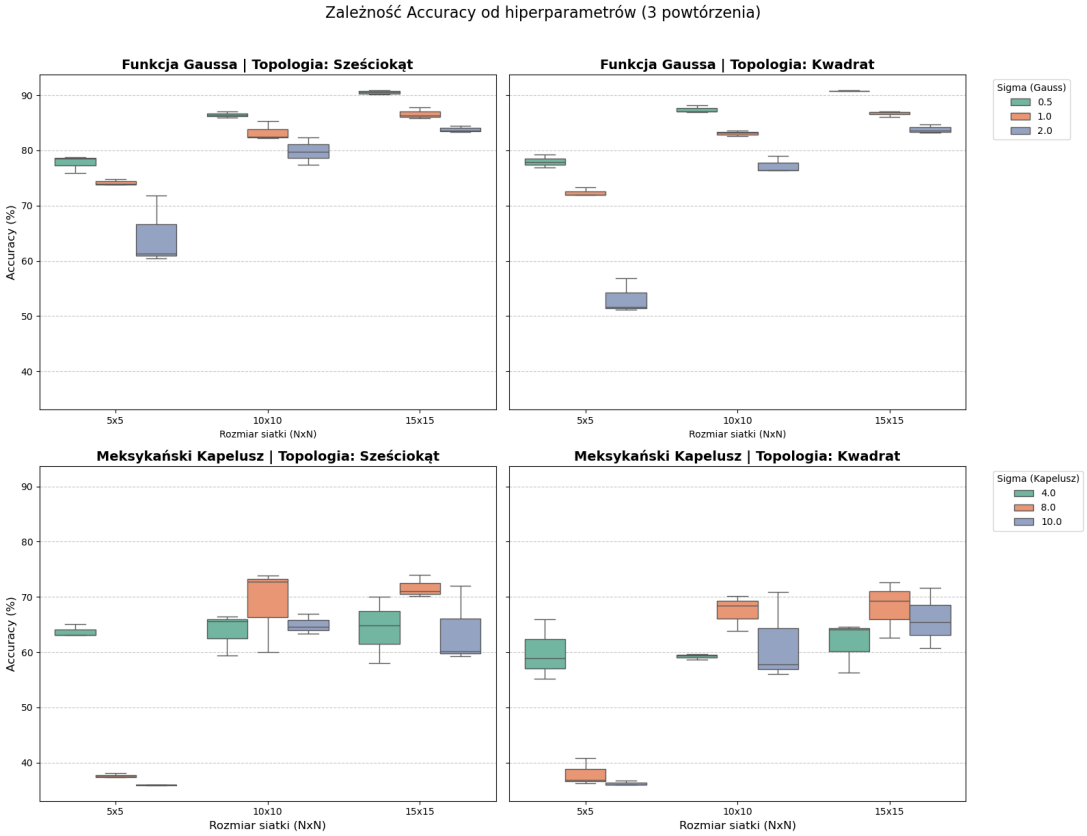
Tabela 5: Średnie wyniki Accuracy wraz z odchyleniem standardowym uzyskane po 3 wywołaniach dla konkretnych kombinacji hiperparametrów modelu dla zbioru MNIST. Wartości posortowane malejąco po średnim Accuracy.

	Rozmiar	Sigma	Funkcja	Topologia	Średnia Acc (%)	Odchylenie Std
0	15x15	0.5	funkcja Gaussa	kwadrat	90.770	0.104
1	15x15	0.5	funkcja Gaussa	szesciokat	90.517	0.392
2	10x10	0.5	funkcja Gaussa	kwadrat	87.387	0.693
3	15x15	1.0	funkcja Gaussa	kwadrat	86.670	0.498
4	15x15	1.0	funkcja Gaussa	szesciokat	86.650	1.028
5	10x10	0.5	funkcja Gaussa	szesciokat	86.430	0.542
6	15x15	2.0	funkcja Gaussa	kwadrat	83.827	0.818
7	15x15	2.0	funkcja Gaussa	szesciokat	83.810	0.565
8	10x10	1.0	funkcja Gaussa	szesciokat	83.330	1.676
9	10x10	1.0	funkcja Gaussa	kwadrat	83.123	0.493
10	10x10	2.0	funkcja Gaussa	szesciokat	79.853	2.497
11	5x5	0.5	funkcja Gaussa	kwadrat	77.993	1.210
12	5x5	0.5	funkcja Gaussa	szesciokat	77.710	1.561
13	10x10	2.0	funkcja Gaussa	kwadrat	77.280	1.524
14	5x5	1.0	funkcja Gaussa	szesciokat	74.183	0.554
15	5x5	1.0	funkcja Gaussa	kwadrat	72.387	0.800
16	15x15	8.0	meksykanski kapelusz	szesciokat	71.707	2.023
17	10x10	8.0	meksykanski kapelusz	szesciokat	68.863	7.715
18	15x15	8.0	meksykanski kapelusz	kwadrat	68.200	5.110
19	10x10	8.0	meksykanski kapelusz	kwadrat	67.477	3.276
20	15x15	10.0	meksykanski kapelusz	kwadrat	65.967	5.483
21	10x10	10.0	meksykanski kapelusz	szesciokat	64.953	1.874
22	5x5	2.0	funkcja Gaussa	szesciokat	64.557	6.346
23	15x15	4.0	meksykanski kapelusz	szesciokat	64.343	6.003
24	10x10	4.0	meksykanski kapelusz	szesciokat	63.827	3.813
25	15x15	10.0	meksykanski kapelusz	szesciokat	63.817	7.107
26	5x5	4.0	meksykanski kapelusz	szesciokat	63.787	1.085
27	15x15	4.0	meksykanski kapelusz	kwadrat	61.650	4.624
28	10x10	10.0	meksykanski kapelusz	kwadrat	61.547	8.101
29	5x5	4.0	meksykanski kapelusz	kwadrat	59.993	5.456
30	10x10	4.0	meksykanski kapelusz	kwadrat	59.217	0.499
31	5x5	2.0	funkcja Gaussa	kwadrat	53.253	3.180
32	5x5	8.0	meksykanski kapelusz	kwadrat	38.003	2.433
33	5x5	8.0	meksykanski kapelusz	szesciokat	37.660	0.412
34	5x5	10.0	meksykanski kapelusz	kwadrat	36.303	0.439
35	5x5	10.0	meksykanski kapelusz	szesciokat	35.943	0.090

Tabela 6: Średnie wyniki Accuracy wraz z odchyleniem standardowym uzyskane po 3 wywołaniach dla konkretnych kombinacji hiperparametrów modelu dla zbioru HAR. Wartości posortowane malejąco po średnim Accuracy.



Rysunek 9: Wartości Accuracy w zależności od funkcji, topologii, rozmiaru siatki oraz wartości sigma dla zbioru danych MNIST.



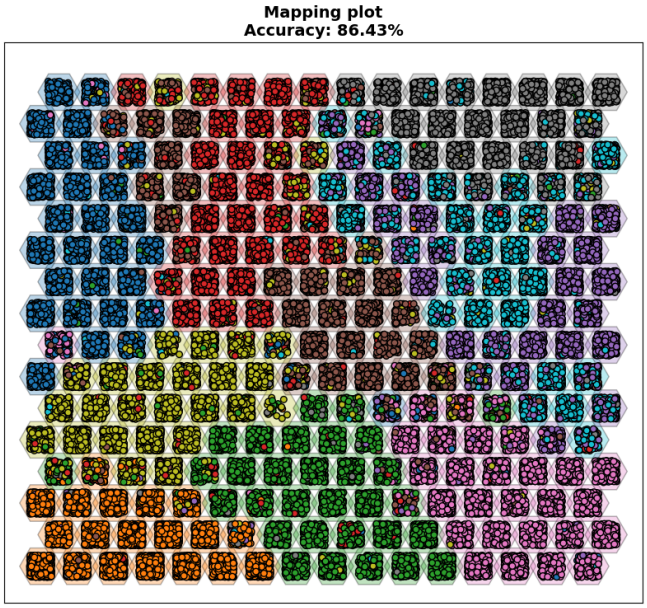
Rysunek 10: Wartości Accuracy w zależności od funkcji, topologii, rozmiaru siatki oraz wartości sigma dla zbioru danych HAR.

Analizując wyniki, można zauważyć, że były one gorsze niż dla prostszych zbiorów hexagon i cube. Ponadto funkcja

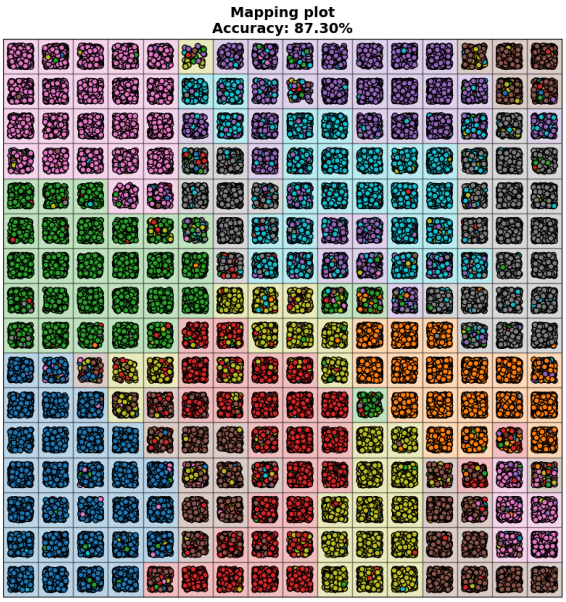
Gaussa dawała znacząco lepsze rezultaty od meksykańskiego kapelusza, a zwiększanie rozmiaru siatki zazwyczaj poprawiało wartość Accuracy. Modele różniące się jedynie topologią osiągały bardzo zbliżone wyniki, dlatego nie można jednoznacznie stwierdzić wyższości żadnej z nich.

Dwa najlepsze modele dla danych MNIST zostały przetrenowane również na pełnych danych przy 6 epokach i współczynniku wygaszania równym 3. Uzyskane mapy trafień są widoczne na wykresach 11. Z analizy wynika, że niewiele jest neuronów zawierających reprezentantów wyłącznie jednej klasy. Mimo to, próbki należące do klas innych niż przypisana do danego neuronu stanowią zdecydowaną mniejszość. Dodatkowo sieć dzieli zbiór na liczbę klastrów bardzo zbliżoną do rzeczywistej liczby klas.

Mapy trafień dwóch najlepszych modeli dla danych HAR są widoczne na wykresach 12. W tym przypadku znaczna część neuronów zawiera reprezentantów wyłącznie jednej klasy. Nieliczne próbki należące do klas innych niż przypisana do danego neuronu pojawiają się głównie na granicach obszarów. Dodatkowo warto zaznaczyć, że sieć skutecznie łączy sąsiadujące ze sobą neurony w rozległe, spójne terytoria, które odpowiadają rzeczywistym klasom w danych.

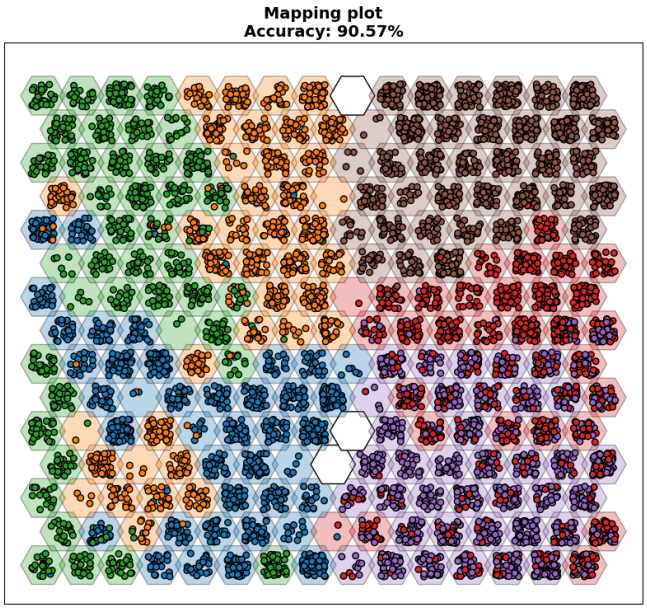


(a) topologia sześciokąta

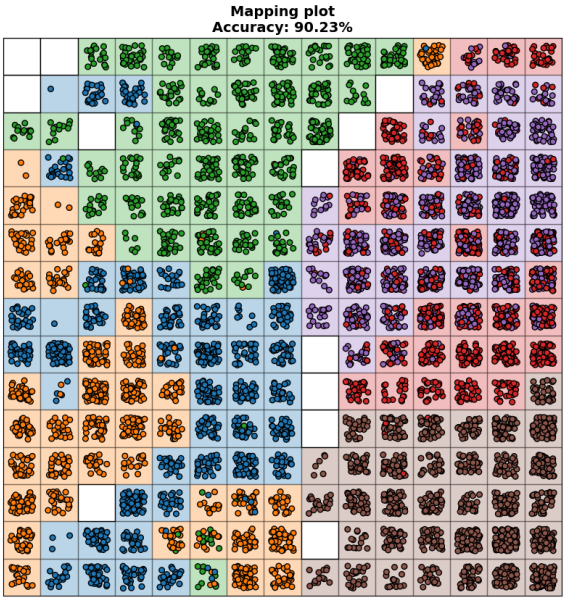


(b) topologia kwadratu

Rysunek 11: Mapy trafień siatki Kohonena rozmiaru 16x16 dla zbioru MNIST z sigmą równą 0.5 i funkcją Gaussa dla różnych topologii wraz z wyliczoną wartością Accuracy.



(a) topologia sześciokąta



(b) topologia kwadratu

Rysunek 12: Mapy trafień siatki Kohonena rozmiaru 15x15 dla zbioru HAR z sigmą równą 0.5 i funkcją Gaussa dla różnych topologii wraz z wyliczoną wartością Accuracy.

Wnioski i podsumowanie

Podsumowując przeprowadzone eksperymenty, zaimplementowana sieć Kohonena udowodniła swoją użyteczność jako wydajne narzędzie do nienadzorowanej klasteryzacji oraz wizualizacji wielowymiarowych danych. Przeprowadzona analiza wyników dla różnych architektur pozwala na sformułowanie wniosków.

Funkcja Gaussa okazała się rozwiązaniem bardziej stabilnym, pozwalającym na osiąganie znacząco wyższych wyników. Z kolei meksykański kapelusz potrafił ostrzej zarysować granice między klastrami.

Promień sąsiedztwa miał znaczący wpływ na wyniki sieci. Zbyt mała wartość powodowała krzyżowanie połączeń siatki, podczas gdy zbyt duża skutkowała nadmiernym przyciąganiem się neuronów i zbijaniem ich w jednym obszarze, co drastycznie obniżało skuteczność klasteryzacji. Co istotne, optymalny zakres tego parametru zależał od użytej funkcji - funkcja Gaussa dawała najlepsze rezultaty dla niższych wartości, podczas gdy meksykański kapelusz wymagał wartości wyższych.

Eksperymenty jednoznacznie wykazały, że zwiększanie rozmiaru siatki wpływa na wzrost Accuracy.

W praktyce różnice w osiągach między siatką kwadratową a sześciokątną były marginalne. Na badanych zbiorach obie topologie radziły sobie bardzo podobnie.

Sieć doskonale radziła sobie z prostymi, syntetycznymi zbiorami (hexagon, cube), natomiast przyłożenie algorytmu do złożonych, rzeczywistych danych wielowymiarowych (MNIST, HAR) wiązało się z naturalnym spadkiem dokładności dopasowania.

Ostatecznie, dobrze nastrojona sieć Kohonena potrafiła wyodrębnić w przestrzeni danych rozległe i jednorodne terytoria, których liczba zwykle odpowiadała rzeczywistej liczbie ukrytych w danych klas. Stanowi to potwierdzenie wysokiej skuteczności algorytmu w nienadzorowanej klasteryzacji oraz czytelnej wizualizacji wielowymiarowych danych.

Zakres użycia LLM

W trakcie realizacji projektu oraz przygotowywania sprawozdania wykorzystano model językowy Gemini. Służył on jako wsparcie w procesie korekty stylistycznej i gramatycznej tekstu. Dodatkowo model wykorzystano do konsultacji programistycznych przy optymalizacji i debugowaniu tworzonego kodu.